

			参数量	显存 GB	
230323	ChatYuan-large-v2	双语	0.7B	0.4 (INT4)	普通显卡 cpu 手机
	glm4_9b			约14.5	
	llama_30B_q4			20	
	llama_13B_q8			15	
	llama_13B_q4			8	
	flan_t5_xxl_q8			13	
	flan_t5_xxl_q4			7	
	llama_7B			14	
	llama_7B_q4			5	
	fairseq_gpt_13B_q8			15	
	fairseq_gpt_13B_q4			9	
	opt_30B_q4			19	
	gptneox_20B_q4			13	
	gptj_6B_q4			4	
	Llama-3				

Llama 3 对中文的支持效果欠佳，经常会出现你用中文提问，它用英文或中文+英文回复的现象
中文微调后: llama3-Chinese-chat Llama3-Chinese

			参数量	显存 GB	
230323	llama3-Chinese-chat	双语	0.7B	0.4 (INT4)	普通显卡 cpu 手机
	llama3-Chinese-chat				

7B参数的4种常见类型
所需推理显存计算如下：
float 7 * 4 = 28 GB
half / BF16 7 * 2 = 14 GB
int8 7 * 1 = 7 GB
int4 7 * 0.5 = 3.5 GB

			参数量	显存 GB	
	llama2_30B_q4			20	
	llama2_13B_q8			15	
	llama2_13B_q4			8	
	llama2_7B			14	
	llama2_7B_q4			5	
Llama 3 对中文的支持效果欠佳，经常会出现你用中文提问，它用英文或中文+英文回复的现象 中文微调后: llama3-Chinese-chat Llama3-Chinese					
	llama3-8B			约15	
	llama3-70B			过大	

7B参数的4种常见类型
所需推理显存计算如下：
float 7 * 4 = 28 GB
half / BF16 7 * 2 = 14 GB
int8 7 * 1 = 7 GB
int4 7 * 0.5 = 3.5 GB

		显存 GB
23/07/19	llama2_30B_q4	20
	llama2_13B_q8	15
	llama2_13B_q4	8
	llama2_7B	14
	llama2_7B_q4	5
Llama 3 对中文的支持效果欠佳，经常会出现你用中文提问，它用英文或中文+英文回复的现象 中文微调后: llama3-Chinese-chat Llama3-Chinese		
24/04/18	llama3-8B	约15
	llama3-70B	过大
23/10/27	glm3_6b	13+
24/01/16	glm4_9b	14.5

ChatYuan-large-v2
https://blog.csdn.net/qq_43692950/article/details/131743987
项目
<https://github.com/clue-ai/ChatYuan>

7B参数的4种常见类型
所需推理显存计算如下：
float $7 * 4 = 28$ GB
half / BF16 $7 * 2 = 14$
GB
int8 $7 * 1 = 7$ GB
int4 $7 * 0.5 = 3.5$ GB

3dmm 系数 马普所

评价指标
生成的怎么样
哪些论文